

Lancer une IA locale avec Ollama

Gratuite & Sécurisée



www.legroupecif.com

Comprendre avant de commencer

Ollama

Ollama est l'outil qui télécharge, gère et lance les modèles IA en une seule commande.

Il y en a d'autres, mais c'est une bonne option.

Pensez-y comme un gestionnaire de paquets mais pour les IA : une commande pour tout faire.

Il expose aussi une API locale (port 11434) compatible avec des apps tierces (Open WebUI, Continue, etc.).

VRAM

La VRAM (Video RAM) est la mémoire embarquée dans votre carte graphique (GPU).

Les modèles IA s'exécutent idéalement entièrement en VRAM, c'est là que la vitesse se joue.

Pas de GPU ? Pas de problème : Ollama utilise la RAM système, mais c'est 3-10× plus lent.

Si votre machine possède 2 carte graphiques (intégré + dédié)
Définissez Ollama en "Haute performance" dans vos paramètres.

*Sur Windows: Paramètres → Système → Ecran → Graphiques → Ajouter l'application Bureau 'ollama' → **Préférences GPU "Hautes Performances"***

Quantisation

Les modèles existent en plusieurs précisions : :q4, :q5, :q8, :fp16...

Q4 = 4 bits par poids → 2× plus léger, légère perte de qualité.

Q8 = 8 bits par poids → meilleure qualité, plus lourd.

Sans suffixe = la valeur recommandée par défaut est choisie automatiquement.

Installation 1/2

1

Installer Ollama

Rendez-vous sur **ollama.com** et cliquez sur Download.

Windows

Téléchargez OllamaSetup.exe et double-cliquez. C'est tout.

macOS

Téléchargez Ollama.app, glissez-le dans Applications et lancez-le.

Linux

```
curl -fsSL  
https://ollama.com/install.sh  
| sh
```

2

Vérifier l'installation

Ouvrez un terminal (PowerShell / Terminal.app) et tapez :

```
ollama --version
```

- ✓ Numéro de version affiché → tout est bon.
- ✗ Erreur ? Redémarrez votre machine et réessayez.

3

Connaître sa VRAM

Dans le terminal, selon votre OS :

Windows

```
dxdiag
```

→ onglet Affichage → Afficher la mémoire (VRAM)

macOS

```
system_profiler  
SPDisplaysDataType
```

Linux

```
nvidia-smi
```

→ colonne Memory-Usage

Installation 2/2

4

Télécharger un modèle

Choisissez un modèle selon votre VRAM (**voir slides suivantes**) puis :

```
ollama pull gemma3:4b
```

Le nom de votre modèle



⚠ À savoir avant de télécharger

- Les modèles pèsent de 1 à 20 Go selon leur taille.
- **Le modèle doit idéalement tenir entièrement en VRAM.**
- S'il déborde sur la RAM système, les performances chutent fortement.
- Règle d'or : si trop lent → choisir un modèle plus petit.

5

Lancer et discuter

Via l'application Ollama (recommandé)

Dans l'app Ollama → cliquez sur New Chat

Interface graphique intégrée : sélectionnez votre modèle et discutez directement. Aucun réglage supplémentaire.

Via le terminal (direct)

```
ollama run gemma3:4b
```

Tapez votre message → Entrée..

Choisir son modèle selon sa VRAM

<2 Go VRAM/ CPU

smollm2:1.7b

texte

HuggingFace

Ultra-léger 1.7B. Parfait pour tester Ollama ou tourner sur CPU/Raspberry Pi.

```
ollama pull smollm2:1.7b
```

llama3.2:1b

texte

Meta

Très rapide, bon pour routing / agents

```
ollama pull llama3.2:1b
```

qwen2.5:0.5b

texte

Alibaba

Le plus petit Qwen, multilingue

```
ollama pull qwen2.5:0.5b
```

tinyllama

texte

Meta

1.1B, le plus léger possible

```
ollama pull tinyllama
```

moondream2

vision

DeepSeek

Vision légère ~1.8B

```
ollama pull moondream
```

Choisir son modèle selon sa VRAM

4 Go VRAM

gemma3:4b

texte

vision

logique

Google

Polyvalent, excellent rapport qualité/taille

```
ollama pull gemma3:4b
```

llama3.2:3b

texte

Meta

3B compact, bon généraliste rapide

```
ollama pull llama3.2:3b
```

phi4-mini

texte

logique

Microsoft

3.8B paramètres, exceptionnel en raisonnement pour sa taille

```
ollama pull phi4-mini
```

qwen2.5:3b

texte

code

Alibaba

3B multilingue, solide en code et compréhension du français

```
ollama pull qwen2.5:3b
```

Starcoder2:3b

code

HuggingFace

600+ languages, license permissive

```
ollama pull starcoder2:3b
```

Granite3.1:2b

texte

MoE

IBM

MoE long-context, faible latence

```
ollama pull granite3.1:2b
```

Choisir son modèle selon sa VRAM

6 Go VRAM

mistral:7b

texte

Mistral AI

7B, français natif, rédaction fluide et naturelle, rapide

```
ollama pull mistral:7b
```

qwen2.5:7b

texte

code

logique

Alibaba

Meilleur généraliste multilingue, fort en code et en français.
Recommandé pour débiter.

```
ollama pull qwen2.5:7b
```

deepseek-coder:6.7b

code

DeepSeek

Spécialisé code : complétion, debug, refactoring. Fort sur Python, JS...

```
ollama pull deepseek-coder:6.7b
```

qwen2.5:5b

texte

code

Alibaba

Bon équilibre taille/perf

```
ollama pull qwen2.5:5b
```

Codegemma:7b

code

Google

Completion FIM (fill-in-the-middle), éditeur

```
ollama pull codegemma:7b
```

Deepseek-r1:7b

logique

code

DeepSeek

Raisonnement "thinking"

```
ollama pull deepseek-r1:7b
```

qwen2.5vl:7b

texte

vision

Alibaba

Meilleur modèle vision-langage à ce tier. Analyse d'images et documents.

```
ollama pull qwen2.5vl:7b
```

Choisir son modèle selon sa VRAM

8 Go VRAM

llama3.1:8b

texte

logique

Meta

La référence en 8b, 128K contexte

```
ollama pull llama3.1:8b
```

gemma3:4b (Q8)

texte

vision

logique

Google

Multimodal : comprend images + texte. Fort en raisonnement.

```
ollama pull gemma3:4b-it-q8_0
```

qwen2.5-coder:7b

code

logique

Alibaba

Meilleur modèle code à ce tier

```
ollama pull qwen2.5-coder:7b
```

codellama:7b

code

Meta

Spécialisé code : complétion, debug. Compatible avec Continue (VS Code).

```
ollama pull codellama:7b
```

deepseek-r1:8b

code

logique

DeepSeek

Raisonnement avancé avec chain-of-thought visible. Affiche sa réflexion étape par étape.

```
ollama pull deepseek-r1:8b
```

qwen3.8

texte

code

logique

Alibaba

Dernière génération Qwen. Thinking intégré, meilleur 8B polyvalent.

```
ollama pull qwen3.8b
```


Choisir son modèle selon sa VRAM

16 Go VRAM

llama3.3:70b-q4

texte

code

logique

Meta

70B quantisé Q4, proche GPT-4 en qualité pour un usage courant.

```
ollama pull llama3.3:70b-q4_K_M
```

qwen2.5:14b

texte

code

logique

Alibaba

Excellent en maths, code et raisonnement. Fort en français... et en chinois

```
ollama pull qwen2.5:14b
```

mixtral:8x7b

texte

MoE

Mistral AI

Architecture MoE : 8 experts, activés à la demande. Très rapide pour sa taille.

```
ollama pull mixtral:8x7b
```

llava:13b

texte

vision

LLaVA

Vision + langage : analyse photos, graphiques, interfaces, captures d'écran.

```
ollama pull llava:13b
```

phi4:14b

texte

logique

Microsoft

Raisonnement scientifique et mathématique exceptionnel pour 14B.

```
ollama pull phi4:14b
```

mistral-nemo:12b

texte

Mistral AI

12B performant, contexte long (128k tokens). Très bon en multilingue.

```
ollama pull mistral-nemo:12b
```

Choisir son modèle selon sa VRAM

24 Go+ VRAM

gemma3:27b

texte

vision

logique

Google

Multimodal haute qualité. Vision avancée, très bon généraliste.

```
ollama pull gemma3:27b
```

deepseek-r1:32b

texte

code

logique

DeepSeek

Chain-of-thought visible + MoE. Top en maths et code complexe.

```
ollama pull deepseek-r1:32b
```

qwen2.5:32b

texte

code

logique

Alibaba

Meilleur open-source généraliste du moment selon plusieurs benchmarks.

```
ollama pull qwen2.5:32b
```

llama3.3:70b

texte

code

logique

Meta

70B pleine précision : qualité maximale, proche des meilleurs modèles commerciaux.

```
ollama pull llama3.3:70b
```

qwen2.5vl:32b

texte

vision

logique

Alibaba

Vision-langage 32B : analyse fine d'images, documents, diagrammes, OCR.

```
ollama pull qwen2.5vl:32b
```

Choisir son modèle selon sa VRAM

Plus de modèles:

ollama.com/library

Astuces & commandes utiles

Lister les modèles installés

```
ollama list
```

Supprimer un modèle

```
ollama rm llama3.2
```

Infos détaillées sur un modèle

```
ollama show gemma3:4b
```

Mettre à jour un modèle (re-pull)

```
ollama pull gemma3:4b
```

Chercher des modèles disponibles

→ ollama.com/library

Exposer l'API REST locale (port 11434)

```
ollama serve
```



À savoir

- Pas de GPU ? Ollama tourne aussi sur CPU avec la RAM. Plus lent, mais fonctionnel. Les petits modèles ($\leq 4B$) restent très utilisables.
- Quantisation : les suffixes :q4_K_M, :q8 indiquent la précision. Q4 = 2× plus léger, Q8 = meilleure qualité. Sans suffixe = défaut recommandé.
-  **Si votre modèle est trop lent** → choisissez-en un plus petit. Le modèle doit idéalement tenir entièrement en VRAM.